

Большие данные и хранилища данных

Билет 1

1. Что понимается под Big Data? Раскройте характеристики Volume, Velocity, Variety, Veracity и Value и объясните, как каждая из них влияет на выбор архитектуры хранения и обработки данных.
2. Опишите этапы ETL-процесса: извлечение, преобразование и загрузка. Чем отличается ETL и ELT процесс?
3. Что такое Data Quality и почему качество данных критически важно для бизнеса? Перечислите основные измерения качества и приведите пример нарушения каждого из них.

Билет 2

1. Сравните OLTP- и OLAP-системы по назначению, структуре запросов, характеру обновлений и требованиям к производительности. Приведите примеры задач для каждого класса систем.
2. Почему увеличение пропускной способности может приводить к росту задержки?
3. Опишите архитектуру Apache Airflow: роль Scheduler, Webserver, Executor, Metadata Database и Worker. Как они взаимодействуют при запуске DAG?

Билет 3

1. Почему классические реляционные СУБД могут испытывать ограничения при работе с Big Data?
2. Какие факторы влияют на пропускную способность и задержку системы обработки данных? Объясните, как найти баланс между этими показателями.
3. Какие метрики следует отслеживать для инфраструктуры хранения: емкость, IOPS, пропускную способность, задержку, ошибки и состояние реплик? Какие тенденции должны вызывать предупреждение?

Билет 4

1. Что такое многомерный куб (OLAP-куб)? Объясните назначение измерений, иерархий и мер и приведите пример куба для анализа продаж.
2. Как должен восстанавливаться конвейер после частичного сбоя? Рассмотрите контрольные точки, повторные попытки, атомарную публикацию, очистку промежуточных данных и повторный запуск.
3. Что такое DAG в оркестрации ETL/ELT? Как задаются зависимости, параллельные ветви, повторные попытки и условия продолжения или остановки конвейера?

Билет 5

1. Опишите операции с многомерными данными: сечение, транспонирование, свертка и детализация. Как каждая операция изменяет представление аналитического отчета?
2. Сравните полную и инкрементальную загрузку данных. В каких случаях применяется каждый подход и как определить изменившиеся записи без повторной обработки всего источника?

3. Как организовать Data Quality для пакетной загрузки? Опишите проверки до запуска, во время преобразования, после загрузки и перед открытием данных пользователям.

Билет 6

1. Сравните схемы «звезда» и «снежинка» в хранилище данных. Какие преимущества и недостатки имеет каждая схема с точки зрения запросов, хранения и сопровождения?
2. Какие операции очистки данных можно выполнить в Apache Spark? Рассмотрите работу с пропусками, дубликатами, некорректными значениями, форматами дат и выбросами.
3. Сравните пропускную способность, задержку и масштабируемость системы данных. Почему улучшение одного показателя может ухудшить другой и как измерять каждый из них?

Билет 7

1. Что такое транзакция? Раскройте свойства ACID и объясните, почему требования к транзакционности в OLTP-системах обычно строже, чем в аналитических хранилищах.
2. Как выполнить сверку данных между источником и хранилищем?
3. Что такое catchup и backfill в Apache Airflow? В каких случаях требуется обработать пропущенные интервалы и как избежать неконтролируемого одновременного запуска большого числа задач?

Билет 8

1. Какие модели хранения данных применяются в современных информационных системах? Сравните реляционную, документную, ключ-значение и колоночную модели по структуре данных и типичным сценариям использования.
2. Порассуждайте: сервис собирает события поведения пользователей с высокой скоростью и ежедневно получает справочники из ERP. Как объединить эти потоки для построения аналитической витрины?
3. Сформулируйте критерии приемки сквозной платформы данных по полноте, точности, согласованности, уникальности, пропускной способности, задержке, масштабируемости, надежности и отказоустойчивости.

Билет 9

1. Что такое хранилище данных и чем оно отличается от операционной базы данных? Объясните свойства предметной ориентированности, интегрированности, историчности и неизменяемости данных.
2. Что такое оконные функции SQL? Объясните назначение конструкций PARTITION BY, ORDER BY и рамки окна и приведите пример расчета накопительного итога или ранга.
3. Какие проблемы решает Data Lineage?

Билет 10

1. Опишите основные архитектуры хранилищ данных: централизованное корпоративное хранилище, независимые витрины и архитектуру с зависимыми витринами. В каких условиях уместен каждый подход?
2. Опишите конвейер формирования DDS в Apache Spark от чтения нескольких источников до записи результата. Где следует размещать проверки схемы, качества и количества записей?
3. Опишите план аварийного восстановления платформы данных. Какие данные, конфигурации, метаданные и секреты необходимо резервировать и как проверять возможность восстановления?

Билет 11

1. Сравните вертикальное и горизонтальное масштабирование реляционной СУБД. Какие ограничения возникают при переходе от одного мощного сервера к распределенной архитектуре?
2. Какими способами можно оптимизировать пакетный конвейер? Рассмотрите параллельное чтение, фильтрацию на ранних этапах, партиционирование, уменьшение shuffle и настройку размеров файлов.
3. Чем оркестрация конвейеров данных отличается от простого запуска задач по расписанию? Какие функции оркестратора необходимы для управления зависимостями и состоянием процессов?

Билет 12

1. Чем шардинг отличается от репликации в реляционных СУБД? Какие задачи решает каждый механизм и какие новые сложности появляются при их совместном использовании?
2. Сравните ETL и ELT. Как место выполнения преобразований влияет на требования к источникам, вычислительным ресурсам, времени загрузки и гибкости повторной обработки?
3. Какие измерения Data Quality становятся наиболее критичными при потоковой обработке? Объясните контроль своевременности, полноты, дубликатов и порядка событий в реальном времени.

Билет 13

1. Что такое виртуальное хранилище данных? Как оно предоставляет единое представление разнородных источников без обязательного физического переноса всех данных?
2. Что такое обратное давление (backpressure) и контрольные точки в потоковой обработке? Как они помогают стабилизировать систему и восстановить состояние после сбоя?
3. Как организовать контрольные ворота качества перед публикацией данных? Опишите пороги, блокирующие и предупреждающие проверки, карантин и порядок обработки отклонений.

Билет 14

1. Какими свойствами обладает облачное хранилище данных? Сравните его с локальным хранилищем по масштабированию, оплате ресурсов, доступности, управлению и рискам зависимости от поставщика.

2. Как конвейер должен обрабатывать изменение схемы источника? Сравните добавление поля, изменение типа и удаление столбца с точки зрения совместимости и повторной загрузки.
3. Как Airflow может ожидать готовность внешней системы или файла? Сравните использование сенсоров, проверочных задач и событийных механизмов и укажите риск длительного ожидания.

Билет 15

1. Что такое сеть хранения данных (SAN)? Опишите ее основные компоненты и объясните, чем доступ к блочным устройствам через SAN отличается от работы с обычной сетевой файловой системой.
2. Почему большое количество мелких файлов ухудшает работу распределенного хранилища и Spark? Какие подходы применяются для укрупнения файлов и контроля их целевого размера?
3. Порассуждайте: как распределить ответственность за данные между владельцами источников, командой платформы и аналитиками? Какие процессы мониторинга и реагирования необходимы для надежной эксплуатации?

Билет 16

1. Опишите общий жизненный цикл сбора и хранения информации: от возникновения данных в источнике до их размещения в целевой системе. Какие контрольные точки необходимы на каждом этапе?
2. Что такое отображение «источник — приемник» (source-to-target mapping)? Какие правила преобразования, ключи и ограничения должны быть зафиксированы до реализации загрузки?
3. Сравните технические, бизнес- и операционные метаданные. Какие пользователи платформы работают с каждым видом и какие решения принимают на их основе?

Билет 17

1. Какую роль выполняет СУБД в информационной системе? Рассмотрите управление схемой, запросами, транзакциями, конкурентным доступом, безопасностью, резервным копированием и восстановлением.
2. Как в Apache Spark выполняются преобразование и нормализация схемы данных? Объясните приведение типов, переименование полей, вычисление новых атрибутов и унификацию справочников.
3. Как обеспечить высокую доступность оркестратора и каталога метаданных? Какие компоненты требуют резервирования и что произойдет при отказе базы метаданных или планировщика?

Билет 18

1. Сравните физическое, виртуальное и облачное хранилища данных. Какие критерии следует учитывать при выборе: производительность, стоимость, масштабируемость, отказоустойчивость и управляемость?
2. Как подготовить к объединению данные из источников с разными форматами дат, кодировками, единицами измерения и часовыми поясами? Опишите последовательность нормализации.
3. Как совместное использование метрик, логов и Data Lineage помогает диагностировать проблему с данными? Опишите последовательность расследования от алерта до поиска затронутых витрин.

Билет 19

1. Что такое консолидация данных и какие бизнес-задачи она решает? Объясните, почему простого копирования данных из нескольких систем недостаточно для получения единой аналитической картины.
2. Порассуждайте: когда для загрузки в современное облачное хранилище предпочтительнее ELT, а когда ETL? Обоснуйте выбор с учетом чувствительных данных и сложности преобразований.
3. Опишите расследование инцидента, при котором аналитическая витрина обновилась не полностью. Какие логи, метрики, проверки качества и сведения о зависимостях следует изучить?

Билет 20

1. Какие проблемы возникают при интеграции данных из разнородных источников? Рассмотрите различия схем, форматов, кодировок, справочников, идентификаторов и временных зон.
2. Какие типы окон применяются при потоковой обработке: фиксированные, скользящие и сессионные? Как выбор окна влияет на расчет метрик в реальном времени?
3. Что такое профилирование данных и как на его основе формируются правила Data Quality? Какие статистики и распределения следует анализировать до разработки проверок?

Билет 21

1. Сравните строковое и колоночное хранение данных. Почему строковый формат удобен для транзакционных операций, а колоночный — для аналитических запросов и агрегаций?
2. Что такое детальный слой данных (DDS) и какое место он занимает между сырыми данными и аналитическими витринами? Какие требования предъявляются к его структуре и истории изменений?
3. Спроектируйте ежедневный DAG в Airflow для загрузки данных из нескольких источников, формирования DDS, проверки качества и публикации витрины. Какие зависимости должны быть заданы?

Билет 22

1. Чем детальный слой данных отличается от агрегированного слоя? Какие задачи решаются на каждом уровне и почему важно сохранять исходную гранулярность данных?
2. Как организовать контроль качества в потоковой обработке без остановки всего потока? Объясните разделение корректных и проблемных событий, карантин и последующую дообработку.
3. Как интегрировать Apache Airflow с OpenMetadata? Какие сведения о запусках, зависимостях и качестве данных полезно передавать в каталог для построения Data Lineage?

Билет 23

1. Что такое таблица фактов, таблица измерений и гранулярность факта? Как неверный выбор гранулярности приводит к двойному счету или потере аналитических возможностей?

2. Какие операции подготовки данных выполняются перед загрузкой в хранилище? Рассмотрите профилирование, очистку, приведение типов, стандартизацию, валидацию и обработку пропусков.

3. Как Data Lineage используется для анализа влияния изменений? Порассуждайте, как определить затронутые таблицы, отчеты и ответственных при изменении поля источника.

Билет 24

1. Сравните единое корпоративное хранилище и набор предметных витрин данных. Как выбранная архитектура влияет на согласованность показателей, скорость внедрения и стоимость сопровождения?

2. Опишите модель распределенных вычислений на примере обработки большого набора файлов. Как данные разбиваются на части, задачи распределяются по узлам, а частичные результаты объединяются?

3. Как обеспечить аудируемость конвейера данных? Какие сведения о запусках, версиях кода, параметрах, входных и выходных наборах должны сохраняться для последующего расследования?

Билет 25

1. Объясните принцип разделения вычислительных ресурсов и хранения данных в облачных аналитических системах. Какие преимущества и ограничения дает независимое масштабирование этих слоев?

2. Какие причины появления дубликатов возможны в ETL/ELT-процессе? Опишите способы обнаружения и удаления дублей с использованием бизнес-ключей и технических идентификаторов.

3. Что такое логирование и какие требования предъявляются к полезным журналам работы конвейера? Объясните уровни событий, контекст, идентификатор запуска и защиту от утечки чувствительных данных.

Билет 26

1. Сравните блочное, файловое и объектное хранение данных. Для каких компонентов платформы больших данных целесообразно применять каждый тип?

2. Как выбрать ключ партиционирования для таблицы хранилища? Объясните связь с фильтрами запросов, равномерностью распределения, количеством разделов и стоимостью их обслуживания.

3. Какие эксплуатационные показатели следует установить для конвейера данных: успешность запусков, длительность, свежесть, объем, пропускную способность и задержку? Как выбирать пороговые значения?

Билет 27

1. Что означает разделение данных на «горячие», «теплые» и «холодные» уровни хранения? Как частота доступа и срок хранения влияют на размещение данных и стоимость инфраструктуры?

2. Сравните пакетную и потоковую обработку данных. Как различаются их архитектура, гарантии обработки, требования к ресурсам и типичные сценарии применения?

3. Чем согласованность данных отличается от уникальности? Какие проверки позволяют обнаружить противоречия между системами и повторяющиеся сущности?

Билет 28

1. Что такое распределенная система? Назовите ее основные свойства и объясните, какие преимущества и сложности возникают при распределении данных и вычислений между несколькими узлами.
2. Как выполняется объединение больших наборов данных в Apache Spark? Почему JOIN может вызвать shuffle и перекос данных и какими способами можно уменьшить эти издержки?
3. Как в Airflow управлять повторными попытками, тайм-аутами, ограничением параллелизма и пулами ресурсов? Почему эти настройки важны для стабильности хранилища?

Билет 29

1. Как устроена распределенная файловая система? Опишите разбиение файлов на блоки, размещение копий, хранение метаданных и восстановление после отказа узла.
2. Какие виды валидации следует выполнять в конвейере данных? Сравните проверку схемы, диапазонов, ссылочной целостности, бизнес-правил и межтабличных зависимостей.
3. Как связать планирование емкости с автоматическим масштабированием и алертингом? Какие пороги должны приводить к добавлению ресурсов, а какие — к расследованию неэффективной нагрузки?

Билет 30

1. Какие функции выполняет менеджер ресурсов в распределенной вычислительной системе? Объясните управление очередями, выделением CPU и памяти, приоритетами и изоляцией приложений.
2. Спроектируйте обработку в Apache Spark для формирования DDS из трех источников: транзакций, клиентского справочника и файлов с курсами валют. Опишите очистку, соединение и загрузку результата.
3. Что такое Data Lineage? Объясните различия между lineage на уровне систем, таблиц и столбцов и приведите пример цепочки происхождения показателя.

Билет 31

1. Какие модели вычислений применяются для обработки больших данных? Сравните поэтапную модель MapReduce, конвейерное выполнение и вычисления на основе DAG.
2. Как обрабатывать запоздавшие события в потоковом конвейере? Объясните роль времени события, времени обработки, водяных знаков и допустимой задержки.
3. Почему устаревшие данные могут считаться некачественными, даже если они полны и точны? Приведите пример и объясните, как измерять свежесть и своевременность.

Билет 32

1. Что такое локальность данных и почему она важна в распределенных системах? Как перенос вычислений к данным помогает уменьшить сетевой трафик и время выполнения задач?

2. Как выбрать стратегию партиционирования данных при записи из Spark? Объясните влияние ключа партиции и размера файлов на чтение, загрузку и обслуживание хранилища.
3. Какие цели решает мониторинг платформы данных? Разделите метрики инфраструктуры, хранилища, вычислений и конвейеров и приведите примеры ключевых показателей.

Билет 33

1. Как в распределенной системе связаны масштабируемость, надежность и отказоустойчивость? Почему добавление узлов само по себе не гарантирует линейного роста производительности и доступности?
2. Опишите сквозной конвейер загрузки данных в облачное хранилище: сбор, временное размещение, преобразование, контроль качества, публикация и обновление метаданных.
3. Почему Apache Airflow не следует использовать как основной механизм обработки и передачи больших объемов данных? Как правильно разделить обязанности Airflow, Spark и хранилища?

Билет 34

1. Опишите слои инфраструктуры хранения больших данных: физические ресурсы, сеть, системы хранения, вычислительный слой, платформенные сервисы и средства управления. Как эти слои взаимодействуют?
2. Что такое агрегирование и обогащение данных? Приведите примеры этих преобразований и объясните, как избежать искажения исходного смысла показателей.
3. Объясните различия между полнотой и точностью данных. Может ли набор данных быть полным, но неточным, или точным, но неполным? Приведите примеры.

Билет 35

1. Какие задачи включает управление информационной инфраструктурой?
2. Какова роль Apache Spark при формировании детального слоя данных (DDS)?
3. Что такое DAG, Task, Operator, Sensor и XCom в Apache Airflow? Объясните назначение каждого понятия и границы их применения.