

Коллоквиум по модулю 2

«Подготовка данных»

Дисциплина: «Технологии хранения и обработки больших данных»

Общие положения

Параметр	Значение
Модуль	2. Подготовка данных
Компетенция	BD-2.2 (Уровень C)
Форма проведения	Устный опрос
Время подготовки	30-40 минут
Структура	теоретические вопросы

Назначение оценочного средства

Коллоквиум по модулю 2 «Подготовка данных» предназначен для текущего контроля студентов и оценки уровня сформированности компетенций в области интеграции, подготовки и управления качеством данных.

Результаты коллоквиума позволяют преподавателю:

- Выявить пробелы в теоретических знаниях студентов.
- Скорректировать содержание дальнейшего обучения.
- Оценить готовность студентов к выполнению практических задач по подготовке данных.

Проверяемые результаты обучения и индикаторы

Компетенция	Индикатор	Уровень	Дескриптор освоения
BD-2. Способен определять требования к наборам данных, анализировать и обеспечивать качество данных	BD-2.2	C	Собирает данные из разнородных источников, проверяет их корректность и реализует процессы консолидации, очистки и загрузки данных с использованием ETL и ELT

Список вопросов для подготовки к коллоквиуму

Раздел 1. Консолидация и интеграция данных

1. **Понятие консолидации данных.** Обобщенная схема процесса консолидации. Цели и задачи консолидации данных в корпоративных системах.
2. **Интеграция данных из разнородных источников.** Проблемы, возникающие при интеграции. Подходы к решению проблем несовместимости форматов и схем данных.
3. **ETL-процессы: определение, этапы, назначение.** Детальное описание каждого этапа: Extract (извлечение), Transform (преобразование), Load (загрузка). Особенности реализации на практике.
4. **ELT-процессы: определение, отличие от ETL.** Сравнительный анализ ETL и ELT. Когда какой подход следует применять? Преимущества и ограничения каждого подхода.

5. **Типы данных:** структурированные, полуструктурированные, неструктурированные. Примеры каждого типа. Особенности работы с каждым типом данных при подготовке к загрузке в хранилище.

6. **Форматы представления данных.** CSV, JSON, XML, Parquet. Сравнение форматов, сценарии использования, преимущества и недостатки.

7. **Инструменты ETL/ELT.** Обзор современных инструментов: Apache Airflow, Apache NiFi, Talend, AWS Glue. Назначение, ключевые возможности, сравнение.

Раздел 2. Подготовка данных к загрузке

8. **Этапы подготовки данных.** Очистка, нормализация, преобразование, обогащение. Детальное описание каждого этапа.

9. **Методы очистки данных (Data Cleaning).** Обработка пропусков (удаление, заполнение средним/медианой, интерполяция). Удаление дубликатов. Обработка выбросов. Обработка некорректных форматов.

10. **Нормализация и стандартизация данных.** Min-Max нормализация, Z- стандартизация. Когда какой метод применяется? Влияние на качество последующего анализа.

Раздел 3. Качество данных (Data Quality)

11. **Понятие качества данных.** Определение. Почему качество данных критично для систем ИИ и аналитики?

12. **Основные показатели качества данных (DQ).** Полнота (Completeness), точность (Accuracy), своевременность (Timeliness), согласованность (Consistency), уникальность (Uniqueness), допустимость (Validity). Определение каждого показателя, примеры проверок.

13. **Профилирование данных (Data Profiling).** Что это такое? Какие задачи решает? Какие метрики вычисляются при профилировании?

14. **Методы и инструменты контроля качества данных.** Apache NiFi, Great Expectations, OpenMetadata. Назначение, ключевые возможности. Как организовать автоматические DQ-проверки в пайплайне?

Раздел 4. Оркестрация конвейеров данных

15. **Apache Airflow: назначение и архитектура.** DAG (Directed Acyclic Graph), операторы, сенсоры, XCom. Основные понятия и принципы работы.

16. **Организация оркестрации ETL/ELT-процессов с помощью Airflow.** Создание DAG, настройка расписания, обработка ошибок, логирование.

17. **Понятие Data Lineage (происхождения данных).** Что это такое? Зачем нужно отслеживать происхождение данных? Как это помогает в управлении качеством и доверии к данным?

18. **Инструменты для Data Lineage.** OpenMetadata, Apache Atlas. Назначение, ключевые возможности. Как организовать сбор метаданных и построение графа происхождения данных?

Раздел 5. Обогащение данных

19. **Понятие обогащения данных (Data Enrichment).** Что это такое? Какие задачи решает?

20. **Внутреннее обогащение.** Генерация признаков (Feature Engineering). Примеры создания новых признаков на основе существующих.

21. **Внешнее обогащение.** Использование открытых API, парсинг веб-данных (web scraping), интеграция с внешними базами знаний. Примеры обогащения данных из внешних источников.

Критерии оценивания

Формат	Макс. балл	Критерии
2 теоретических вопроса	12 (по 6 за вопрос)	Полнота ответа (2 балла), глубина понимания (2 балла), примеры (2 балла)

Формат	Макс. балл	Критерии
Итого	12	

Шкала перевода баллов в оценку

Баллы	Оценка
10-12	Отлично
7-9	Хорошо
4-6	Удовлетворительно
0-3	Неудовлетворительно

Рекомендуемые источники для подготовки

1. Битченков Д.И., Злобина М.С., Ермаков С.Г. Ключевые проблемы внедрения ETL/ELT-процессов и методы их преодоления. – Интеллектуальные технологии на транспорте, 2025.
2. Материалы лекций модуля 2 (конспекты, презентации).
3. Материалы лабораторных работ по интеграции данных и ETL/ELT-процессам.
4. Официальная документация:
 - Apache Airflow: airflow.apache.org/docs
 - Apache NiFi: nifi.apache.org/docs
 - Label Studio: labelstud.io/docs
 - CVAT: cvat.ai/docs
 - OpenMetadata: open-metadata.org/docs

Правила использования внешних источников, программных инструментов и генеративного ИИ

На коллоквиуме разрешены только минимально необходимые источники. Для подготовки к коллоквиуму разрешается использовать генеративный ИИ только для уточнения сложных понятий, не для генерации готовых ответов.

Требования к воспроизводимости и самостоятельности выполнения работы

Ответ должен демонстрировать собственное понимание материала. Основные определения должны быть сформулированы точно. Ответ должен быть логически структурирован. Студент должен понимать, как знания применяются на практике.