

Занятие 2.2. Интеграция данных из открытых источников и реализация ETL/ELT-процессов

В рамках лабораторной работы необходимо разработать процесс интеграции данных из открытого источника и организовать их последовательную загрузку в хранилище. В качестве источника допускается использовать открытый API, веб-сайт, файловый набор данных или иной общедоступный сервис.

Разработанное решение должно обеспечивать получение исходных данных, их сохранение в необработанном виде, очистку, преобразование и загрузку в целевой слой хранилища. Выбор подхода ETL или ELT необходимо обосновать с учетом структуры данных, объема, частоты обновления и возможностей выбранной платформы хранения.

Этапы выполнения:

1. Выбрать открытый источник данных и описать его назначение, способ доступа, формат ответа, структуру основных сущностей и ограничения использования. Зафиксировать перечень атрибутов, необходимых для дальнейшей обработки и анализа.
2. Подготовить окружение для выполнения интеграционного процесса. Сервисы хранения, обработки и вспомогательные компоненты рекомендуется развернуть в Docker-контейнерах с использованием docker-compose конфигурации.
3. Реализовать этап извлечения данных из источника. Процесс должен учитывать пагинацию, ограничения частоты запросов, временную недоступность источника, повторные попытки выполнения и корректное завершение при получении ошибочного ответа.
4. Организовать загрузку исходных данных в слой ODS или аналогичную зону необработанных данных. Необходимо сохранить исходную структуру данных и добавить технические атрибуты: дату и время загрузки, идентификатор источника, идентификатор запуска процесса и признак актуальности записи.
5. Реализовать преобразование данных: удалить дубликаты, привести типы, обработать пропуски, унифицировать наименования полей и значения справочников. При необходимости выполнить обогащение данных сведениями из дополнительного открытого источника.

Примеры преобразований: нормализация дат и времени, очистка текстовых полей, приведение денежных значений к единому формату, выделение вложенных объектов в отдельные сущности.

6. Загрузить подготовленные данные в целевой слой хранилища. Структура таблиц или коллекций должна соответствовать задачам дальнейшего анализа. Выбранный вариант ETL или ELT необходимо аргументировать.
7. Обеспечить идемпотентность и возможность инкрементальной загрузки. Повторный запуск процесса для одного и того же интервала не должен приводить к неконтролируемому появлению дубликатов или нарушению целостности данных.

В качестве механизма инкрементальной загрузки могут использоваться временная метка изменения, последовательный идентификатор, контрольная сумма или сохранение состояния последнего успешного запуска.

Для защиты необходимо предоставить отчет, описывающий источник данных, архитектуру решения, выбранный подход ETL/ELT, структуру слоев хранилища и результаты проверок. К отчету должны быть приложены исходный код процессов, конфигурационные файлы и инструкция по запуску.

Обязательным условием является демонстрация полного цикла обработки: получение данных из открытого источника, загрузка исходных записей, выполнение преобразований, повторный запуск без появления некорректных дубликатов и просмотр итоговых данных в хранилище.