

Тест Модуль 2.
Занятие 2.1. Лекция
(индикатор BD-2.2)

Консолидация данных. Обобщенная схема процесса консолидации.

Интеграция данных из разнородных источников. ETL/ELT процессы.

Подготовка данных к загрузке в хранилище.

Цель: проверка знаний студента этапов процесса консолидации данных, понимание процесса трансформации данных под условия задачи, понимания процесса проверки данных на корректность и знаний специфики подготовки датасетов для задач машинного обучения.

Вопрос 1

Отметьте основные этапы консолидации данных по принципу ETL:

- 1) сбор информации из баз данных, CRM/ERP систем, таблиц или внешних сервисов;
- 2) удаление ошибок и дубликатов, приведение данных к единому стандарту;
- 3) агрегация данных;
- 4) перемещение данных в единое хранилище

Вопрос 2.

Соотнесите архитектурные модели управления данными с последовательностью этапов:

ETL

Извлечение данных -> Преобразование данных
происходит -> Загрузка в финальное хранилище

ELT

Извлечение данных -> Загрузка в финальное
хранилище -> Преобразование данных

Вопрос 3.

Выберите утверждения относящиеся к ETL консолидации:

- 1) Консолидация происходит на отдельном сервере или в оперативной памяти ETL-инструмента
- 2) Консолидация происходит внутри целевого облачного/ аналитического хранилища данных
- 3) В целевой БД хранятся только очищенные, агрегированные и строго структурированные данные
- 4) В целевой БД хранятся как сырые «грязные» логи, так и финальные консолидированные данные
- 5) Гибкость изменений низкая: если изменились правила консолидации, старые данные нужно извлекать заново

- 6) Гибкость изменений высокая: сырые данные уже в БД, при изменении консолидации нужно переписать SQL скрипт трансформации

Вопрос 4.

Выберите утверждения относящиеся к ETL консолидации:

- 1) Консолидация происходит на отдельном сервере или в оперативной памяти ETL-инструмента
- 2) Консолидация происходит внутри целевого облачного/ аналитического хранилища данных
- 3) В целевой БД хранятся только очищенные, агрегированные и строго структурированные данные
- 4) В целевой БД хранятся как сырые «грязные» логи, так и финальные консолидированные данные
- 5) Гибкость изменений низкая: если изменились правила консолидации, старые данные нужно извлекать заново
- 6) Гибкость изменений высокая: сырые данные уже в БД, при изменении консолидации нужно переписать SQL скрипт трансформации

Вопрос 5.

Выберите основные типы разнородностей при интеграции данных:

- 1) системная (техническая);
- 2) семантическая (смысловая)
- 3) синтаксическая (форматы)
- 4) инструментальная (разные ОС и протоколы передачи данных)

Вопрос 6.

Выстройте обобщенную схему процесса консолидации данных в соответствии с порядком шагов:

Шаг 1	Извлечение данных из разнородных источников
Шаг 2	Трансформация данных в нужную аналитику форму и агрегация данных до нужного уровня
Шаг 3	Сопоставление и дедубликация данных
Шаг 4	Загрузка данных в финальный слой хранения
Шаг 5	Очистка и валидация данных

Вопрос 7.

Какие из преимуществ и недостатков относятся к архитектурной модели управления данными ETL:

- 1) максимальная скорость загрузки; высокая гибкость
- 2) в хранилище попадают только чистые, идеальные данные; экономится место в DWH; проще соблюдать требования безопасности
- 3) если логика расчетов изменилась, нужно заново скачивать сырые данные из систем-источников
- 4) быстро растет объем занимаемого места в DWH; сырой слой может превратиться в «болото данных» если им не управлять.

Вопрос 8.

Какие из преимуществ и недостатков относятся к архитектурной модели управления данными ETL:

- 1) максимальная скорость загрузки; высокая гибкость
- 2) в хранилище попадают только чистые, идеальные данные; экономится место в DWH; проще соблюдать требования безопасности
- 3) если логика расчетов изменилась, нужно заново скачивать сырые данные из систем-источников
- 4) быстро растет объем занимаемого места в DWH; сырой слой может превратиться в «болото данных» если им не управлять.

Вопрос 9.

Упорядочите этапы подготовки данных к загрузке в хранилище:

Шаг 1	Очистка данных – устранение дубликатов, обработка пропусков, фильтрация аномалий
Шаг 2	Маппинг и трансформация структуры – связывание полей из разных систем и изменение архитектуры таблиц
Шаг 3	Профилирование – анализ структуры и качества входящих данных перед какими-либо манипуляциями
Шаг 4	Нормализация и унификация – приведение разнородных данных к единому стандарту
Шаг 5	Маскирование и безопасность – защита персональных и конфиденциальных данных
Шаг 6	Обогащение данных - добавление контекста для удобства будущей аналитики

Вопрос 10.

Какие утверждения относительно проблемы «болото данных» (Data Swap) являются верными?

- 1) Проблема в разы чаще возникает при использовании подхода ELT.
- 2) Проблема чаще возникает при использовании подхода ETL.
- 3) В Data Swap реализовано строгое разделение на слои внутри базы данных с изоляцией данных по стадиям готовности.
- 4) Использование систем автоматического документирования и политика владения данными предназначены для предотвращения проблемы Data Swap.

Критерии оценивания Теста по лекционному занятию 2.1. Модуля 2

Итоговый балл	Оценка	Уровень освоения индикаторов BD – 3.1	Качественная характеристика
85-100	Отлично (5)	С (средний)	Студент отлично ориентируется в этапах процесса консолидации данных, имеет глубокое понимание процесса трансформации данных под условия задачи и процесса проверки данных на корректность, владеет спецификой подготовки датасетов для задач машинного обучения. Предоставил ответы на все (или почти все) вопросы теста верно.
70-84	Хорошо (4)	С (средний)	Студент хорошо ориентируется в этапах процесса консолидации данных, имеет уверенное понимание процесса трансформации данных под условия задачи и процесса проверки данных на корректность, владеет

			спецификой подготовки датасетов для задач машинного обучения. Почти на все вопросы теста дан верный ответ или верный неполный ответ. Ошибки допущены в 2-3 ответах.
50-69	Удовлетворительно (3)	Б (базовый)	Студент ориентируется в этапах процесса консолидации данных, имеет понимание процесса трансформации данных под условия задачи и процесса проверки данных на корректность, владеет спецификой подготовки датасетов для задач машинного обучения. Ответы даны на большую часть вопросов, присутствуют неполные ответы.
<50	Неудовлетворительно (2)	Не готов	Студент не ориентируется в этапах процесса консолидации данных, не имеет базового понимания процесса трансформации данных под условия задачи и процесса проверки данных на корректность, не владеет спецификой подготовки датасетов для задач машинного обучения. Ответы даны менее чем на половину вопросов, много

			ошибок и неполных ответов.
--	--	--	-------------------------------