

Контрольная работа по модулю 3

«Технологии и инструменты обработки данных»

Дисциплина: «Технологии хранения и обработки больших данных»

Общие положения

Параметр	Значение
Модуль	3. Технологии и инструменты обработки данных
Компетенции	BD-4.1 (Уровень П), BD-4.3 (Уровень П), PL-1.3 (Уровень С)
Время выполнения	90 минут
Максимальный балл	35 баллов
Структура	3 блока: тестирование, практическое задание, задание с использованием ИИ

Блок 1. Тестовая часть (14 баллов)

Выберите один правильный ответ из предложенных вариантов.

Вопрос 1. Компетенция BD-4.1. Основы распределенной обработки (1 балл)

Какая технология используется для распределенной обработки больших данных?

- A. Microsoft Excel
- B. Apache Spark
- C. SQL Server Management Studio
- D. Google Sheets

Вопрос 2. Компетенция BD-4.1. Пакетная и потоковая обработка (1 балл)

Какая из перечисленных технологий подходит для обработки потоков данных в режиме реального времени?

- A. Apache Kafka
 - B. PostgreSQL
 - C. MySQL
 - D. TensorFlow
-

Вопрос 3. Компетенция BD-4.1. Модель MapReduce (1 балл)

Что такое MapReduce в контексте больших данных?

- A. Алгоритм машинного обучения
 - B. Модель программирования для обработки больших данных
 - C. Метод компрессии данных
 - D. Средство визуализации данных
-

Вопрос 4. Компетенция BD-4.1. Преимущества распределенных систем (1 балл)

Какое преимущество имеет распределенное хранилище данных?

- A. Легкость интеграции с любым программным обеспечением
 - B. Высокая отказоустойчивость и масштабируемость
 - C. Минимальная стоимость внедрения
 - D. Возможность работы без доступа к сети
-

Вопрос 5. Компетенция BD-4.1. Облачные платформы (1 балл)

Что из перечисленного относится к облачным платформам для работы с большими данными?

- A. Notepad++
 - B. Google BigQuery
 - C. Adobe Photoshop
 - D. IntelliJ IDEA
-

Вопрос 6. Компетенция BD-4.1. Процессы преобразования данных (1 балл)

Как называется процесс преобразования необработанных данных в структурированный вид?

- A. MapReduce
 - B. RDD (Resilient Distributed Dataset)
 - C. ETL (Extract, Transform, Load)
 - D. DevOps
-

Вопрос 7. Компетенция BD-4.1. Оркестрация конвейеров (1 балл)

Автоматизировать запуск пакетных задач в рамках конвейера обработки больших данных по расписанию можно с помощью:

- A. Apache Kafka
 - B. Apache Airflow
 - C. Apache Hadoop
 - D. PostgreSQL
-

Вопрос 8. Компетенция BD-4.3. Форматы хранения (1 балл)

Формат Parquet считается:

- A. полуструктурированным
 - B. колоночным (столбцовым)
 - C. строковым
 - D. неструктурированным
-

Вопрос 9. Компетенция BD-4.1. Поточковая обработка (1 балл)

Выберите технологию потоковой обработки событий в режиме реального времени:

- A. Spark Streaming
 - B. Apache Hadoop
 - C. MapReduce
 - D. Oracle Database
-

Вопрос 10. Компетенция BD-4.3. Прослеживаемость и качество данных (1 балл)

Что из перечисленного относится к задачам управления метаданными в системах больших данных?

- A. Только хранение сырых данных
 - B. Отслеживание происхождения данных (Data Lineage) и контроль качества
 - C. Исключительно визуализация результатов
 - D. Оптимизация SQL-запросов
-

Вопрос 11. Компетенция BD-4.1. Массово-параллельные системы (1 балл)

Какая характеристика соответствует массово-параллельным системам (Massively Parallel Processing, MPP)?

- A. Последовательная обработка данных на одном узле
 - B. Распределенная обработка с разделением данных между множеством узлов
 - C. Обработка только потоковых данных
 - D. Вычисления только в оперативной памяти без хранения
-

Вопрос 12. Компетенция BD-4.1. Инструменты маршрутизации данных (1 балл)

Apache NiFi используется для:

- A. визуализации результатов аналитики
 - B. маршрутизации потоков больших данных и построения конвейеров преобразования данных
 - C. вычислений в реальном времени
 - D. хранения данных на диске
-

Вопрос 13. Компетенция BD-4.1. Распределенные базы данных (1 балл)

Какая из перечисленных баз данных относится к колоночным (Column-Family) хранилищам?

- A. MongoDB
 - B. Cassandra
 - C. Redis
 - D. Neo4j
-

Вопрос 14. Компетенция BD-4.3. Показатели качества данных (1 балл)

Какой из перечисленных показателей относится к характеристикам качества данных (Data Quality)?

- A. Только объем данных
 - B. Полнота, точность, своевременность, согласованность
 - C. Скорость передачи данных
 - D. Сложность запросов
-

Блок 2. Практическое задание (16 баллов)

Задание 2.1. Компетенции BD-4.1, PL-1.3. Разработка архитектуры конвейера (6 баллов)

Условие: Компания «Данные-Тех» собирает логи посещений своего веб-сайта. Данные поступают в виде файлов логов (формат JSON) в папку /data/raw/ на сервере. Необходимо:

1. Ежедневно обрабатывать новые файлы логов.
2. Очищать данные от дубликатов и записей с отсутствующими обязательными полями.
3. Трансформировать данные: извлекать user_id, page_url, timestamp, session_duration, referrer.
4. Сохранять обработанные данные в партиционированную таблицу в хранилище.
5. Обеспечивать прослеживаемость данных (Data Lineage).
6. Контролировать качество данных на каждом этапе.

Задание:

А. Опишите архитектуру конвейера (2 балла)

Изобразите схему конвейера с указанием всех компонентов, потоков данных и технологий.

В. Напишите код графа зависимостей задач для Apache Airflow (2 балла)

Составьте граф зависимостей задач, который реализует описанный конвейер. Используйте операторы Python или Spark.

С. Напишите код Spark-приложения (2 балла)

Реализуйте на PySpark логику очистки и трансформации логов: удаление дубликатов, фильтрация записей без обязательных полей (user_id, timestamp), извлечение необходимых полей в целевой формат.

Задание 2.2. Компетенция BD-4.3. Анализ и оптимизация (5 баллов)

Условие: у вас есть Spark-приложение, которое обрабатывает 50 ГБ сырых логов за 4 часа. Время выполнения кажется слишком большим. Проанализируйте возможные причины низкой производительности и предложите способы оптимизации.

Задание: перечислите **не менее 4 причин** медленной работы и предложите **конкретные решения** для каждой из них.

Критерии оценки:

- Каждая причина оценивается в 1 балл (всего 4 балла).
 - За аргументированное обоснование решений – бонусный 1 балл.
-

Задание 2.3. Компетенция BD-4.3. Контроль качества данных (5 баллов)

Условие: В конвейере преобразования данных на разных этапах могут возникать ошибки, связанные с качеством данных. Вам необходимо реализовать систему мониторинга качества данных.

Задание:

А. Опишите, какие показатели качества данных (DQ) вы будете проверять (2 балла)

В. Напишите функцию на Python для автоматической проверки качества данных (3 балла)

Реализуйте функцию, которая принимает таблицу данных и возвращает отчет с метриками качества.

Блок 3. Задания с использованием искусственного интеллекта (5 баллов)

Задание 3.1. Компетенция PL-1.3. Генерация тестовых данных с помощью ИИ (2 балла)

Условие: для тестирования конвейера обработки данных вам необходимо сгенерировать синтетический набор журналов веб-сервера в формате JSON.

Задание:

А. Сформулируйте запрос к генеративному искусственному интеллекту (ChatGPT, YandexGPT или GigaChat) для генерации 1000 записей журналов с полями: `user_id`, `page_url`, `timestamp`, `session_duration`, `referrer`. В запросе укажите требования к формату данных, диапазонам значений и структуре JSON. **(1 балл)**

****В.** Получите сгенерированные данные, сохраните их в файл `test_logs.json` и напишите код на Python для чтения этого файла и вывода первых 5 записей. **(1 балл)**

Задание 3.2. Компетенция PL-1.3. Проверка кода с помощью ИИ (3 балла)

Условие: представьте, что вы написали код для очистки и трансформации журналов, но не уверены в его оптимальности. Используйте генеративный искусственный интеллект для проверки кода.

Задание:

А. Сформулируйте запрос к генеративному искусственному интеллекту для проверки следующего кода. В запросе укажите необходимость выявления:

- потенциальных ошибок;
- проблем с производительностью;
- нарушений лучших практик написания кода. **(1 балл)**

```
from pyspark.sql import functions as F
def clean_data(df):
    df = df.dropDuplicates(["user_id"])
    df = df.filter(F.col("price") < 100000)
    df = df.withColumn("year", F.col("year").cast("int"))
    return df
```

****В.** Получите ответ от искусственного интеллекта, зафиксируйте его в отчете. На основе полученных рекомендаций исправьте код и приложите исправленную версию с комментариями, поясняющими внесенные изменения. **(2 балла)**

Критерии оценивания

Блок	Макс. балл	Критерии
Тестовая часть	14	По 1 баллу за каждый правильный ответ
Задание 2.1A	2	Полнота схемы, указание технологий, потоков
Задание 2.1B	2	Корректность графа зависимостей задач, связи, операторы, параметры
Задание 2.1C	2	Чтение, очистка, трансформация, запись
Задание 2.2	5	4 причины (4 балла) и обоснование (1 балл)
Задание 2.3A	2	4-5 показателей качества с примерами
Задание 2.3B	3	Код (2 балла), логика и структура (1 балл)
Задание 3.1A	1	Качество запроса к ИИ, полнота требований
Задание 3.1B	1	Корректность кода для чтения и вывода данных
Задание 3.2A	1	Качество запроса к ИИ для проверки кода
Задание 3.2B	2	Корректность исправлений, наличие комментариев
ИТОГО	35	

Распределение заданий по компетенциям

Компетенция	Дескриптор	Уровень	Задания
BD-4.1	Студент способен обоснованно выбирать технологии обработки больших данных, проектировать архитектуру распределенной обработки и организовывать централизованное хранилище данных с использованием современных технологий (Hadoop, Spark, Iceberg, Airflow)	П	Вопросы 1-7, 9, 11-13; Задание 2.1
BD-4.3	Студент способен внедрять проверки качества данных, настраивать прослеживаемость данных, оценивать качество решений и анализировать влияние качества данных на результаты.	П	Вопросы 8, 10, 14; Задания 2.2, 2.3

Компетенция	Дескриптор	Уровень	Задания
PL-1.3	Студент способен применять основные функции фреймворка PySpark для разработки систем обработки больших данных, писать код для очистки, трансформации и загрузки данных.	С	Задания 2.1 (части В и С), 3.1, 3.2

Шкала перевода баллов в оценку

Баллы	Оценка (5-балльная)
31-35	Отлично
26-30	Хорошо
21-25	Удовлетворительно
0-20	Неудовлетворительно