

Задание 3.7. Формирование Data Lineage и проверок качества данных на базе OpenMetadata

В рамках данной лабораторной работы необходимо развернуть платформу OpenMetadata и использовать ее для каталогизации объектов хранилища, построения происхождения данных (Data Lineage) и централизованного контроля качества данных.

В итоговой модели должны быть представлены источники, таблицы или коллекции слоев ODS и DDS, аналитические витрины и процессы их формирования. Для ключевых наборов данных необходимо назначить ответственных, добавить бизнес-описания и настроить автоматизированные проверки качества.

Этапы выполнения:

1. Развернуть OpenMetadata и необходимые зависимые сервисы в Docker-контейнерах. Конфигурацию развертывания необходимо добавить в проект и описать порядок первоначальной настройки системы.
2. Подключить к OpenMetadata используемые сервисы: базы данных, объектные хранилища, Apache Airflow и, при наличии, средство визуализации. Выполнить сбор технических метаданных и убедиться, что основные объекты доступны в каталоге.
3. Описать ключевые наборы данных: добавить понятные наименования и описания, владельцев, теги, уровень критичности и термины бизнес-гlossария. Выбранные атрибуты должны помогать пользователю определить назначение и ответственность за данные.

Примеры терминов бизнес-гlossария: пользователь, товар, событие, дата загрузки, выручка, рейтинг, активная запись.

4. Сформировать Data Lineage от открытого источника до аналитической витрины. На схеме должны быть отражены переходы между исходными данными, слоями ODS и DDS, результатами проверок и конечными объектами, используемыми для анализа.

Lineage должен позволять ответить на вопросы: откуда получено значение, каким процессом оно преобразовано и какие витрины или отчеты могут быть затронуты при изменении источника.

5. Настроить автоматическое получение lineage из поддерживаемых интеграций. Для зависимостей, которые не удалось определить автоматически, добавить связи вручную или передавать их через API. Необходимо проверить корректность lineage на уровне таблиц и, где возможно, столбцов.

6. Создать наборы проверок качества для критичных таблиц. Необходимо реализовать проверки полноты, уникальности, допустимого диапазона значений, соответствия формату, ссылочной целостности, свежести данных и ожидаемого объема загрузки.

Набор проверок необходимо выбирать с учетом назначения таблицы. Для справочников приоритетны уникальность и ссылочная целостность, для событийных таблиц - свежесть, полнота и контроль объема.

7. Настроить регулярный запуск проверок и сохранение истории результатов. Для неуспешных тестов определить порог срабатывания, ответственного и порядок обработки инцидента. Допускается интеграция запуска проверок с Apache Airflow.
8. Продемонстрировать жизненный цикл проблемы качества: искусственно сформировать некорректные данные, получить неуспешный результат проверки, определить затронутые downstream-объекты по Data Lineage, исправить данные и подтвердить успешное повторное выполнение теста.

Для защиты необходимо предоставить отчет с архитектурой интеграции OpenMetadata, перечнем подключенных сервисов, описанием каталога данных, схемой Data Lineage и таблицей реализованных проверок качества. К отчету следует приложить конфигурационные файлы и код автоматизации загрузки метаданных и запуска тестов.

Обязательным условием является демонстрация веб-интерфейса OpenMetadata: поиск и карточка набора данных, назначенные владельцы и термины, граф происхождения данных, история проверок качества, пример неуспешного теста и подтверждение устранения обнаруженной проблемы.