

Блок 1. Распределённые системы и MPP-архитектуры

Вопрос 1 (одиночный выбор)

Что такое MPP-система (Massively Parallel Processing)?

- A) Система для обработки данных в реальном времени на одном узле
- B) Архитектура распределённой обработки, в которой каждый узел независимо обрабатывает свою часть данных без общего хранилища
- C) Модель хранения данных в реляционных СУБД
- D) Протокол передачи данных между узлами кластера

Правильный ответ: B

Вопрос 2 (множественный выбор)

Какие характеристики относятся к архитектуре Shared-Nothing, используемой в MPP-системах?

- A) Каждый узел имеет собственную память и дисковое хранилище
- B) Все узлы обращаются к общему дисковому массиву (SAN)
- C) Узлы обмениваются данными по сети
- D) Отсутствие единой точки отказа (при правильной реализации)
- E) Общая оперативная память между всеми узлами

Правильные ответы: A, C, D

Вопрос 3 (одиночный выбор)

Какое из утверждений о сравнении MPP и MapReduce является верным?

- A) MapReduce лучше подходит для интерактивных SQL-запросов, чем MPP
- B) MPP оптимизирована для пакетной обработки больших объёмов данных с высокой задержкой
- C) MapReduce ориентирован на пакетную обработку с записью промежуточных результатов на диск, а MPP — на выполнение сложных аналитических запросов в памяти
- D) Обе архитектуры идентичны по производительности

Правильный ответ: С

Блок 2. Распределённая файловая система HDFS

Вопрос 4 (одиночный выбор)

Какую роль выполняет NameNode в архитектуре HDFS?

- A) Хранит фактические блоки данных
- B) Хранит метаданные файловой системы (дерево каталогов, соответствие блоков файлам, расположение реплик)
- C) Выполняет вычисления MapReduce
- D) Управляет ресурсами кластера

Правильный ответ: В

Вопрос 5 (одиночный выбор)

Что такое heartbeat в контексте HDFS?

- A) Команда копирования файлов между узлами
- B) Периодический сигнал от DataNode к NameNode о своей работоспособности
- C) Механизм шифрования данных
- D) Протокол аутентификации пользователей

Правильный ответ: В

Вопрос 6 (одиночный выбор)

Какой коэффициент репликации по умолчанию используется в HDFS?

- A) 1
- B) 2
- C) 3
- D) 5

Правильный ответ: С

Вопрос 7 (множественный выбор)

Какие из утверждений о HDFS являются верными?

- A) HDFS оптимизирована для режима «записать один раз, читать много раз»
- B) HDFS поддерживает произвольную модификацию файлов в середине
- C) HDFS обеспечивает отказоустойчивость за счёт репликации блоков
- D) HDFS хранит данные в виде блоков фиксированного размера (по умолчанию 128 МБ)
- E) HDFS предназначена для хранения миллионов маленьких файлов

Правильные ответы: A, C, D

Вопрос 8 (одиночный выбор)

Какая команда HDFS-клиента используется для загрузки локального файла в распределённое хранилище?

- A) `hdfs dfs -get`
- B) `hdfs dfs -put`
- C) `hdfs dfs -copy`
- D) `hdfs dfs -upload`

Правильный ответ: B

Блок 3. Менеджер ресурсов YARN

Вопрос 9 (множественный выбор)

Какие компоненты входят в архитектуру Apache YARN и какие роли они выполняют?

- A) `ResourceManager` — глобальный арбитр ресурсов кластера
- B) `NodeManager` — агент на каждом узле, управляющий контейнерами
- C) `ApplicationMaster` — компонент, отвечающий за конкретное приложение (например, Spark-приложение)
- D) `NameNode` — хранит метаданные файловой системы
- E) `DataNode` — выполняет задачи MapReduce

Правильные ответы: A, B, C

Блок 4. Фреймворк Apache Spark

Вопрос 10 (одиночный выбор)

Что такое RDD (Resilient Distributed Dataset) в Apache Spark?

- A) Реляционная база данных
- B) Устойчивый распределённый набор данных — фундаментальная абстракция Spark для работы с данными
- C) Формат хранения данных в HDFS
- D) Компонент YARN

Правильный ответ: B

Вопрос 11 (одиночный выбор)

Что такое ленивые вычисления (lazy evaluation) в Apache Spark?

- A) Выполнение всех операций сразу при их объявлении
- B) Отложенное выполнение трансформаций до момента вызова действия (action)
- C) Выполнение вычислений только на одном узле
- D) Автоматическое удаление неиспользуемых данных

Правильный ответ: B

Вопрос 12 (одиночный выбор)

Что такое DAG (Directed Acyclic Graph) в контексте Apache Spark?

- A) Формат хранения данных
- B) Ориентированный ациклический граф, представляющий последовательность вычислений
- C) Компонент HDFS
- D) Тип соединения в SQL

Правильный ответ: B

Вопрос 13 (множественный выбор)

Какие из перечисленных операций в Apache Spark являются трансформациями (transformations)?

- A) map()
- B) filter()
- C) count()
- D) join()
- E) collect()

Правильные ответы: A, B, D

Вопрос 14 (множественный выбор)

Какие из перечисленных операций в Apache Spark являются действиями (actions)?

- A) map()
- B) count()
- C) collect()
- D) filter()
- E) show()

Правильные ответы: B, C, E

Вопрос 15 (одиночный выбор)

Какой компонент Spark-приложения координирует выполнение и хранит контекст приложения?

- A) Executor
- B) Worker
- C) Driver
- D) Container

Правильный ответ: C

Вопрос 16 (множественный выбор)

Какие модели запуска Spark-приложений поддерживаются?

- A) YARN
- B) Kubernetes
- C) Standalone
- D) Local
- E) Только YARN

Правильные ответы: A, B, C, D

Блок 5. Apache Trino

Вопрос 17 (одиночный выбор)

Для чего предназначен Apache Trino (бывший PrestoSQL) в архитектуре Lakehouse?

- A) Для пакетной обработки и загрузки больших данных
- B) Для распределённого выполнения интерактивных аналитических SQL-запросов с низкой задержкой
- C) Для оркестрации ETL-процессов
- D) Для управления метаданными хранилища

Правильный ответ: B

Вопрос 18 (одиночный выбор)

Какое ключевое отличие Apache Trino от Apache Spark SQL?

- A) Trino оптимизирован на пропускную способность (throughput), а Spark SQL — на время отклика (latency)
- B) Trino оптимизирован на время отклика (latency) для интерактивных SQL-запросов, а Spark SQL — на пропускную способность для сложной обработки данных
- C) Trino поддерживает только Python API, а Spark SQL — только SQL
- D) Trino может модифицировать данные, а Spark SQL — только читать

Правильный ответ: B

Вопрос 19 (множественный выбор)

Какие утверждения о связке Spark + Trino + Apache Iceberg являются верными?

- A) Spark используется для тяжёлой обработки и записи данных в Iceberg-таблицы
- B) Trino используется для интерактивного чтения и анализа тех же Iceberg-таблиц
- C) Данные должны дублироваться между Spark и Trino для корректной работы
- D) Iceberg обеспечивает единый табличный формат, доступный обоим движкам без конвертации
- E) Trino не может читать данные, записанные Spark

Правильные ответы: A, B, D

Вопрос 20 (множественный выбор)

Какие преимущества даёт использование Trino для аналитических запросов к Iceberg-таблицам?

- A) Возможность выполнять SQL-запросы без запуска JVM-контейнеров Spark
- B) Мгновенный доступ к первым строкам результата (низкая латентность)
- C) Подключение из BI-систем (Tableau, Superset, DBeaver) через стандартный SQL-интерфейс
- D) Возможность модифицировать данные в Iceberg-таблицах так же эффективно, как Spark
- E) Использование скрытого партиционирования Iceberg для оптимизации чтения

Правильные ответы: A, B, C, E

Блок 6. Apache Iceberg и архитектура Data Lake

Вопрос 21 (одиночный выбор)

Зачем при создании Iceberg-таблицы в лабораторных работах явно указывается format-version='2'?

- A) Для ускорения операций чтения
- B) Для поддержки файлов удалений (delete files) и операций обновления на уровне строк (row-level updates), что необходимо для инкрементальной (поточковой) записи данных
- C) Для совместимости с устаревшими версиями Spark
- D) Для включения сжатия данных

Правильный ответ: B

Вопрос 22 (множественный выбор)

Какие преимущества Apache Iceberg имеет перед обычными Parquet-файлами в HDFS?

- A) Поддержка ACID-транзакций
- B) Схемная эволюция (добавление, удаление, переименование колонок без переписывания данных)
- C) Time Travel — доступ к историческим снимкам данных
- D) Скрытое партиционирование с автоматическим управлением физическим размещением файлов
- E) Возможность хранить только структурированные данные

Правильные ответы: A, B, C, D

Вопрос 23 (одиночный выбор)

Что такое скрытое партиционирование (hidden partitioning) в Apache Iceberg?

- A) Партиционирование, при котором пользователь вручную управляет директориями в HDFS
- B) Механизм, при котором Iceberg сам управляет физическим размещением файлов на основе логической стратегии, заданной пользователем
- C) Шифрование данных в партициях
- D) Копирование партиций между кластерами

Правильный ответ: B

Вопрос 24 (множественный выбор)

Какие возможности Apache Iceberg поддерживают развитие хранилища данных в рамках архитектуры Lakehouse?

- A) Совместное чтение одних и тех же данных из Spark, Trino, Flink без конвертации
- B) Инкрементальная запись данных (streaming) при использовании format-version='2'
- C) Откат к предыдущим версиям данных (rollback)
- D) Автоматическая генерация моделей машинного обучения
- E) Поддержка схемной эволюции без переписывания всех данных

Правильные ответы: A, B, C, E

Вопрос 25 (одиночный выбор)

Что такое Lakehouse-архитектура?

- A) Хранилище только неструктурированных данных
- B) Архитектура, сочетающая преимущества Data Lake (масштабируемость, гибкость) и Data Warehouse (ACID-транзакции, управление схемой)
- C) Классическая реляционная СУБД
- D) Локальная файловая система

Правильный ответ: B