

Тест Модуль 3.
Занятие 3.5. Лекция
(индикатор BD-4.3)

Показатели качества данных (DQ). Оркестрация конвейеров данных.

Знакомство с OpenMetadata: Data Lineage

Цель: проверить знание показателей качества данных, навык их идентификации на практических примерах, знание в области оркестрации конвейеров данных.

Вопрос 1.

Соотнесите показатель качества данных (DQ) с его описанием:

Полнота	Характеризует отсутствие противоречий данных при анализе логических связей внутри одного датасета
Корректность	Характеризует отсутствие дубликатов и повторных записей в данных
Точность	Характеризует соответствие данных заданному формату, правилам и бизнес-схеме
Уникальность	Характеризует временную ценность данных
Согласованность	Характеризует степень соответствия данных реальности
Актуальность	Характеризует наличие всех необходимых данных

Вопрос 2.

Инженер данных обнаружил, что в таблице orders (заказы) в столбце delivery_date (дата доставки) у 5% строк стоит значение NULL, хотя по бизнес-логике товар не может быть заказан без указания даты доставки. Какой показатель качества данных (DQ) нарушен?

- 1) Актуальность (Timeliness)
- 2) Полнота (Completeness)
- 3) Точность (Accuracy)
- 4) Уникальность (Uniqueness)

Вопрос 3.

В аналитическое хранилище из двух разных CRM-систем загружаются профили клиентов. В первой системе формат записи телефона +7 (999) 111-22-33, а во второй — 89991112233. Какая метрика качества данных страдает в первую очередь до этапа трансформации?

- 1) Согласованность / Консистентность (Consistency)
- 2) Доступность (Availability)
- 3) Своевременность (Timeliness)
- 4) Уникальность (Uniqueness)

Вопрос 4.

Метрика «Своевременность / Актуальность» (Timeliness) в ELT-архитектуре обычно измеряется как:

- 1) Разница во времени между моментом генерации события в источнике и моментом его доступности для аналитического запроса в DWH.
- 2) Время, затраченное сервером на выполнение SQL-запроса агрегации.
- 3) Количество миллисекунд, необходимых для дедупликации данных в буфере Kafka.
- 4) Частота обновления документации в Data Catalog.

Вопрос 5.

Какие из перечисленных проверок DQ (Data Quality) можно эффективно выполнять «на лету» в процессе стриминга данных (например, внутри Apache Kafka / Flink), не дожидаясь загрузки в DWH? (Выберите ВСЕ верные варианты)

- 1) Проверка структуры JSON на соответствие схеме (Schema Validation).
- 2) Проверка на наличие пустых значений (NOT NULL) в обязательных полях.
- 3) Проверка глобальной уникальности суррогатного ключа по всей исторической таблице за 5 лет.
- 4) Проверка соответствия типов данных (например, что в поле price пришло число, а не текст).

Вопрос 6.

На каком этапе пайплайна проверка качества данных встраивается в ETL архитектуру?

- 1) Качество данных проверяется до загрузки в базу.
- 2) Проверки DQ пишутся на SQL и запускаются асинхронно после загрузки данных в хранилище.

Вопрос 7.

На каком этапе пайплайна проверка качества данных встраивается в ELT архитектуру?

- 1) Качество данных проверяется до загрузки в базу.
- 2) Проверки DQ пишутся на SQL и запускаются асинхронно после загрузки данных в хранилище.

Вопрос 8.

Какие из утверждений относительно оркестрации конвейеров данных являются верными?

- 1) Это процесс автоматического управления, координации и мониторинга последовательности шагов (задач) по обработке данных в рамках ETL/ELT процессов.
- 2) В основе лежит концепция DAG направленного ациклического графа, где узлами являются задачи, а ребрами – зависимости между ними.
- 3) Основной задачей оркестратора конвейеров данных является выполнение тяжелых вычислительных операций, таких как очистка, трансформация и агрегация терабайтов сырых данных внутри своей оперативной памяти перед отправкой в базу данных

Вопрос 9.

Соотнесите ключевые функции оркестратора с их содержанием:

Управление зависимостями	Запуск пайплайнов по расписанию, по событию или через API-триггер
Планирование	Повторные попытки перезапуска задачи и оповещение инженеров об окончательном падении задачи
Мониторинг и логирование	Гарантирует строгий порядок выполнения
Обработка ошибок и отказоустойчивость	Наличие UI-панели (дашборда), где в реальном времени видно статус каждой задачи (Успешно, Ошибка, В процессе) и доступны детальные логи выполнения для отладки

Вопрос 10.

Какие функции выполняет платформа управления данными Open Metadata в разрезе проблемы Data Swamp?

- 1) Анализ влияния изменений

- 2) Отладка ошибок
- 3) Обнаружение мусора
- 4) Удаление мусора

Критерии оценивания Теста по лекционному занятию 3.5. Модуля 3

Итоговый балл	Оценка	Уровень освоения индикаторов BD – 4.3	Качественная характеристика
85-100	Отлично (5)	С (средний)	Студент отлично ориентируется в показателях качества данных, идентифицирует показатели на практических примерах, имеет глубокие знания в области оркестрации конвейеров данных. Предоставил ответы на все (или почти все) вопросы теста верно.
70-84	Хорошо (4)	С (средний)	Студент хорошо ориентируется в показателях качества данных, идентифицирует показатели на практических примерах, имеет уверенные знания в области оркестрации конвейеров данных. Почти на все вопросы теста дан верный ответ или верный неполный ответ. Ошибки допущены в 2-3 ответах.
50-69	Удовлетворительно (3)	Б (базовый)	Студент ориентируется в показателях качества данных, идентифицирует

			показатели на практических примерах, обладает знаниями в области оркестрации конвейеров данных. Ответы даны на большую часть вопросов, присутствуют неполные ответы.
<50	Неудовлетворительно (2)	Не готов	Студент не ориентируется в показателях качества данных, не идентифицирует показатели на практических примерах, не имеет знаний в области оркестрации конвейеров данных. Ответы даны менее чем на половину вопросов, много ошибок и неполных ответов.