

**КОНТРОЛЬНО-ИЗМЕРИТЕЛЬНЫЕ МАТЕРИАЛЫ
ПО ПРОЕКТНОЙ РАБОТЕ**
по дисциплине «Технологии хранения и обработки больших данных»

Контрольно-измерительные материалы (КИМ) предназначены для оценки уровня сформированности компетенций студентов в ходе выполнения проектной работы по дисциплине «Технологии хранения и обработки больших данных».

Цель проектной работы: освоить на практике полный цикл работы инженера данных: от проектирования архитектуры хранения и сбора данных из различных источников до построения прогностической модели и оценки качества всего решения, с использованием современных технологий больших данных, машинного обучения и искусственного интеллекта.

В таблице 1 описаны компетенции, которые формируются по ходу реализации проектной работы.

Таблица 1. Проверяемые результаты освоения компетенций

Код компетенции	Уровень	Дескриптор освоения	Как формируется в проекте
BD-2.2	С	Собирает данные из разнородных источников, проверяет их корректность и реализует процессы консолидации, очистки и загрузки данных с использованием ETL и ELT	Проверка данных на пропуски, дубликаты и некорректные значения. Выбор инструмента разметки (CVAT/Label Studio) для задачи. Разработка инструкции для разметчиков. Организация процесса разметки в команде.
BD-3.1	С	Проектирует архитектуру хранения. Реализует схему больших данных и загрузку данных	Проектирование архитектуры хранения (PostgreSQL, MinIO/HDFS, MongoDB). Реализация схемы больших данных и загрузка данных.
BD-4.1	П	Обосновывает выбор технологий обработки больших данных. Реализует распределенную обработку и организует централизованное хранилище данных.	Обоснованный выбор технологического стека (Spark/Flink, Airflow/Dagster, PostgreSQL/ClickHouse). Реализация распределенной обработки на Spark.
BD-4.3	П	Проектирует и отлаживает конвейеры обработки данных, настраивает оркестрацию, мониторинг, проверки качества и Data Lineage, оценивает надежность и производительность решения	Внедрение показателей качества данных на всех этапах. Формирование Data Lineage. Провести тестирование и оценку качества построенного алгоритма на подготовленных данных.
BD-5.1	С	Студент формирует и обосновывает полный технологический стек проекта, проектирует инфраструктуру с учетом масштабируемости	Выбор и обоснование всего технологического стека. Проектирование архитектуры инфраструктуры. Оценка масштабируемости.

Код компетенции	Уровень	Дескриптор освоения	Как формируется в проекте
PL-1.3	C	Реализует программные компоненты интеграции и преобразования данных, обеспечивает их воспроизводимость и проверяемость	Разработка ETL-скриптов на Python, Spark-приложений, DAG (Directed Acyclic Graph) для Airflow, скриптов для работы с большими данными.
SS-2.1	C	Эффективно коммуницирует с участниками проектной команды при планировании, реализации и анализе результатов работы	Распределение ролей в команде. Планирование этапов работы. Регулярные встречи. Совместная разработка и защита проекта.

Условия и продолжительность выполнения

Тип проекта: командный (3-4 человека). Групповой проект с распределением ролей.

Общая трудоемкость: 18 ак.ч.

Формат сдачи: Презентация (10-15 минут) с демонстрацией работающего прототипа. Отчет.

Задание

Спроектировать и реализовать прототип инфраструктуры для сбора, хранения и обработки больших данных в рамках выбранной предметной области. Сформировать ML-модель на базе собранных данных.

Задачи:

1. Выбрать предметную область и сформулировать бизнес-задачу, используя генеративный ИИ (ChatGPT, YandexGPT, GigaChat).
2. Спроектировать архитектуру хранения и обработки данных.
3. Реализовать ETL/ELT-конвейер для интеграции данных из разнородных источников.
4. Проверить код ETL-процессов с помощью больших языковых моделей.
5. Организовать хранение данных с использованием различных моделей (реляционная, NoSQL, Data Lake).
6. Реализовать распределенную обработку данных с использованием Apache Spark.
7. Внедрить механизмы контроля качества данных (Data Quality) на всех этапах процесса.
8. Настроить оркестрацию конвейера с использованием Apache Airflow.
9. Обеспечить прослеживаемость данных (Data Lineage) с использованием OpenMetadata.
10. Сформировать модель на основе подготовленных данных и применить ее для решения задачи.
11. Подготовить проектную документацию и защитить решение перед комиссией.

Состав команды и распределение ролей

Состав команды: 3-4 человека.

Роль	Ответственность	Компетенции
Data Engineer (Архитектор платформы данных)	Координация команды, проектирование архитектуры, выбор технологического стека, настройка инфраструктуры	BD-3, BD-4, BD-5, SS-2

Роль	Ответственность	Компетенции
Data Engineer (Инженер ETL/ELT и качества данных)	Разработка ETL-процессов, работа с Spark и Airflow, качество данных	BD-4, PL-1
Data Engineer (Инженер по хранению данных)	Проектирование схемы хранения, работа с PostgreSQL, NoSQL, HDFS, оптимизация запросов	BD-3, BD-5
Data Engineer (Инженер по сбору и анализу данных)	Сбор и подготовка данных, обучение и оценка ML-модели, работа с OpenMetadata	BD-2, BD-4, PL-1

Обязательное условие: Каждый участник должен вносить вклад во все этапы проекта и иметь свою зону ответственности.

Каждая команда выбирает **одну из предложенных предметных областей** или предлагает свою (согласовав с преподавателем).

№	Предметная область	Описание	Источники данных
1	Анализ логов веб-сервиса	Сбор и анализ логов доступа к веб-серверу для выявления аномалий, пиков нагрузки, популярных страниц.	Синтетические логи (генератор) или реальные (Kaggle: Web Server Logs).
2	Обработка данных с IoT-датчиков	Сбор и анализ показателей с датчиков температуры, влажности, давления для прогнозирования состояния оборудования.	Синтетические данные (генератор) или открытые (Kaggle: IoT Sensor Data).
3	Анализ транзакций интернет-магазина	Сбор и анализ истории покупок, поведения пользователей для построения рекомендательной системы.	Открытые датасеты (Amazon Reviews, Instacart).
4	Анализ социальных медиа	Сбор и анализ текстовых сообщений и метаданных для выявления тональности и трендов.	Открытые (Kaggle: Sentiment Analysis).
5	Прогнозирование оттока клиентов	Сбор и анализ данных о клиентах телеком-компаний для прогнозирования оттока.	Открытые (Kaggle: Telco Customer Churn).

Требования к формату сдачи и защите

1. Подготовить итоговый отчет по проекту.
2. Подготовить презентацию (10-15 минут).
3. Провести демонстрацию работающего прототипа.

Требования к отчету

Отчет должен содержать следующие разделы:

1. Введение
 - Актуальность выбранной предметной области.
 - Бизнес-задача.
2. Архитектура решения
 - Схема архитектуры (диаграмма потоков данных).
 - Обоснование выбора технологий (таблица сравнения).
3. Модель хранения данных
 - ER-диаграмма.
 - Описание схемы документов (MongoDB/JSONB).
 - Структура Data Lake.
 - Схема Feature Store.
4. ETL/ELT-процесс
 - Описание этапов трансформации.
 - Код Spark-приложений (ключевые фрагменты).
 - DAG для Airflow (схема и описание).
5. Контроль качества данных
 - Описание DQ-проверок.
 - DQ-отчет.
6. ML-модель
 - Описание признаков.
 - Метрики качества.
 - Анализ влияния качества данных на модель.
7. Использование генеративного ИИ при проверке кода
 - Промпты.
 - Результаты.
 - Улучшения.
8. Заключение
 - Итоги проекта.
 - Направления развития (что можно улучшить).
 - Персональный вклад каждого участника (таблица).
9. Приложения
 - Ссылка на репозиторий с кодом.
 - Скриншоты.
 - Код (полный).

Критерии и рубрика оценивания проектной работы

Максимальный балл за проект: 100 баллов

Структура оценки:

- Письменный отчет (30 баллов) – оценивается полнота и качество документации.
- Демонстрация прототипа (30 баллов) – оценивается работающее решение.
- Защита/презентация (20 баллов) – оценивается устная защита и ответы на вопросы.
- Командная работа (20 баллов) – оценивается вклад каждого участника.

Шкала перевода результата в баллы

Сумма баллов	Оценка	Условие
86-100	Отлично	Работа выполнена на высоком уровне, все требования реализованы в полном объеме, проявлена творческая инициатива, использованы дополнительные технологии. Студент демонстрирует глубокое понимание всех аспектов работы.
70-85	Хорошо	Работа выполнена в полном объеме, все требования реализованы, есть незначительные недостатки или недочеты. Студент демонстрирует хорошее понимание основных аспектов работы.
56-69	Удовлетворительно	Работа выполнена на минимально достаточном уровне, большинство требований реализованы, есть существенные недостатки. Студент демонстрирует базовое понимание работы, но допускает ошибки.
0-55	Неудовлетворительно	Работа выполнена не в полном объеме, многие требования не реализованы. Студент не демонстрирует понимания ключевых аспектов работы.

Подробная информация об этапах выполнения проектной работы, критериях оценивания и необходимых информационных ресурсов описана в **методических указаниях к проектной работе** по дисциплине «Технологии хранения и обработки больших данных» для студентов очного отделения направления 09.03.02 «Информационные системы и технологии». Лабораторные работы также являются практическим руководством по выполнению проектной работы.

Правила использования внешних источников, программных инструментов и генеративного ИИ

Разрешено использование официальной документации Apache Hadoop, Spark, Iceberg, Airflow, OpenMetadata, программных инструментов Docker, Jupyter Notebook, VS Code, Git, открытых библиотек и генеративного ИИ при формулировании бизнес-задачи, проверки кода, консультации по синтаксису, поиске стратегий, автоматизации и отчета.

Обучающийся должен уметь объяснить работу любого фрагмента представленного кода на защите. Все запросы к ИИ должны быть задокументированы в отчете (промпт и полученный ответ).

Требования к воспроизводимости и оценке индивидуального вклада

Все компоненты должны разворачиваться из приложенной конфигурации docker-compose и воспроизводить заявленные сценарии запуска, включая повторное выполнение после сбоя.

Работа выполняется в команде. Код должен быть доступен в репозитории с инструкцией по запуску. Исходные данные должны быть доступны по ссылке. Для оценивания индивидуального вклада каждый участник докладывает свою часть работы при защите проекта.

Вспомогательные материалы

Документация:

Apache Spark: <https://spark.apache.org/docs/latest/>

Apache Iceberg: <https://iceberg.apache.org/docs/latest/>

Apache Airflow: <https://airflow.apache.org/docs/>

OpenMetadata: <https://open-metadata.org/docs>

Источники данных:

Kaggle: <https://www.kaggle.com/>

Инструменты:

Docker: <https://www.docker.com/>

Git: <https://git-scm.com/>

Jupyter Notebook: <https://jupyter.org/>

PostgreSQL

ClickHouse

MinIO / HDFS

Облачные платформы:

Yandex Cloud

VK Cloud

SberCloud

Google Cloud